Introduction :

Dans la quête du bien-être sociétal et du progrès, tous les gouvernements partagent une aspiration commune : l'augmentation du taux d'espérance de vie. La mesure du succès d'une nation est de plus en plus liée à la santé et à la longévité de ses citoyens. Pour dévoiler les facteurs complexes qui façonnent les taux d'espérance de vie, nous plongeons dans le domaine de l'analyse de données, en nous concentrant particulièrement sur un ensemble de données exhaustif portant sur l'espérance de vie.

A propos: Life Expectancy Dataset

```
Ce jeu de données spécifie l'espérance de vie en fonction d'une liste d'attributs. Les caractéristiques incluses dans le dataset sont les suivante
```

- Pays (Country),
- Taux d'alphabétisation (literacyrate),
- Homicides pour 100 000 habitants (homicidiesper100k),
- Accès à l'électricité (electricity),
- Niveau de scolarité (Schooling),
- VIH/SIDA (HIV.AIDS),
- Statut (Status),

- Accès à l'eau potable (wateraccess),
- Tuberculose (tuberculosis),
- Taux d'inflation (inflation),
- Dépenses de santé par habitant (healthexppercapita),
- Taux de fécondité (fertilityrate),
- Espérance de vie (lifeexp),
- Accès à Internet (internet),
- PIB par habitant (gdppercapita),
- Émissions de CO2 (CO2),
- Couverture forestière (forest),
- Population urbaine (urbanpop),
- Croissance de la population urbaine (urbanpopgrowth),
- Pays les moins développés (leastdeveloped).

Objectif : Déterminer la qualité de vie dans les pays en fonction de divers indicateurs de santé et de développement en utilisant des techniques de la classification

Importation des Bibliothèques :

```
import pandas as pd
import seaborn as sns
import numpy as np
import matplotlib.pyplot as plt
from sklearn.impute import SimpleImputer
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import AgglomerativeClustering
from scipy.cluster.hierarchy import linkage, dendrogram
from sklearn.preprocessing import LabelEncoder, StandardScaler
from sklearn.neighbors import KNeighborsClassifier
from sklearn.svm import SVC
from sklearn.metrics import confusion_matrix, classification_report
```

Chargement des Données :

```
df = pd.read_csv('lifeexpectancy1.csv')
df2 = pd.read_csv('lifeexpectancy2.csv')
```

Prétraitement des données :

Fusion des deux jeux de donnée, sélection des colonnes pertinentes et traitement des valeurs manquantes.

```
combined_df = pd.concat([df, df2])
combined_df = combined_df.drop_duplicates(subset='Country')

combined_df = combined_df.reset_index(drop=True)
lfe_data = combined_df[["Country","Status","wateraccess","inflation","tuberculosis", "lifeexp","literacyrate","electricity","Schooling"]]

# Création d'un imputeur qui remplace chaque valeur manquante par la moyenne de cette colonne
imputer = SimpleImputer(missing_values=np.nan, strategy='mean')

# Séparation des caractéristiques numériques et catégorielle
num_cols = lfe_data.select_dtypes(include=['float64', 'int64']).columns
cat_cols = lfe_data.select_dtypes(include=['object']).columns

# Application de l'imputeur aux colonnes numériques
lfe_data[num_cols] = imputer.fit_transform(lfe_data[num_cols])
pd.set_option('display.max_rows', None)

print(lfe_data)
```

```
                        Country          Status  wateraccess  inflation  \
    0                   Albania      Developing         95.1   1.613042
    1                   Algeria      Developing         84.0   2.916927
    2                   Armenia      Developing        100.0   2.981309
    3                Azerbaijan      Developing         86.2   1.389726
    4                   Bahrain      Developing        100.0   2.646291
    5                Bangladesh  Leastdeveloped         86.2   6.991639
    6                   Belarus      Developing         99.7  18.119554
    7     Bosnia and Herzegovina      Developing         99.9  -0.897194
```

8	Brazil	Developing	98.1	6.329152	
9	Bulgaria	Developed	99.4	-1.418184	
10	Chile	Developing	99.0	4.718675	
11	China	Developing	94.8	1.921643	
12	Colombia	Developing	91.3	2.897819	
13	Costa Rica	Developing	97.7	4.519346	
14	Croatia	Developed	99.6	-0.215196	
15	Cyprus	Developed	100.0	-1.354989	
16	Dominican Republic	Developing	85.0	2.998642	
17	Ecuador	Developing	86.9	3.589220	
18	El Salvador	Developing	93.1	1.141345	
19	Estonia	Developing	99.6	-0.106175	
20	Georgia	Developing	99.6	3.068812	
21	Greece	Developing	100.0	-1.311211	
22	Guatemala	Developing	92.7	3.418362	
23	Honduras	Developing	90.6	6.129249	
24	Hungary	Developed	100.0	-0.227566	
25	India	Developing	94.1	6.353195	
26	Indonesia	Developing	86.8	6.394925	
27	Italy	Developed	100.0	0.241047	
28	Jamaica	Developing	93.8	8.290006	
29	Jordan	Developing	96.9	2.898932	
30	Kazakhstan	Developing	92.9	6.849450	
31	Kenya	Developing	63.1	6.878155	
32	Latvia	Developed	99.3	0.620491	
33	Lebanon	Developing	99.0	1.854604	
34	Lithuania	Developed	96.6	0.103790	
35	Malta	Developed	100.0	0.310306	
36	Mauritius	Developing	99.9	3.217692	
37	Mexico	Developing	96.1	4.018616	
38	Mongolia	Developing	64.2	12.225448	
39	Morocco	Developing	85.3	0.442310	
40	Myanmar	Leastdeveloped	80.5	5.046411	
41	Nepal	Leastdeveloped	90.7	8.364155	
42	Nicaragua	Developing	86.9	6.035969	
43	Oman	Developing	93.4	1.022343	
44	Pakistan	Developing	91.3	7.189384	
45	Panama	Developing	94.4	2.630931	
46	Paraguay	Developing	96.6	5.028828	
47	Peru	Developing	86.3	3.244963	
48	Philippines	Developing	91.5	3.597823	
49	Poland	Developed	98.3	0.053821	
50	Portugal	Developed	100.0	-0.278153	
51	Romania	Developed	100.0	1.068310	
52	Singapore	Developed	100.0	1.024983	
53	Slovenia	Developed	99.5	0.199344	
54	South Africa	Developing	92.8	6.136020	
55	Spain	Developed	100.0	-0.150870	

L'objectif est d'éliminer les données superflues, corriger les erreurs éventuelles et sélectionner les variables clés nécessaires à notre analyse approfondie. Cette étape nous permettra de disposer d'un jeu de données fiable et optimisé pour identifier les facteurs influant sur la durée de vie.

Exploration des Données :

Analyse des données :

- Pour comprendre la distribution des caractèristiques
- Prendre connaissance des valeurs manquantes (si **présente**)

```
1 lfe_data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 138 entries, 0 to 137
Data columns (total 9 columns):
 #   Column        Non-Null Count  Dtype  
---  ------        --------------  -----  
 0   Country       138 non-null    object 
 1   Status        138 non-null    object 
 2   wateraccess   138 non-null    float64
 3   inflation     138 non-null    float64
 4   tuberculosis  138 non-null    float64
 5   lifeexp       138 non-null    float64
 6   literacyrate  138 non-null    float64
 7   electricity   138 non-null    float64
 8   Schooling     138 non-null    float64
dtypes: float64(7), object(2)
memory usage: 9.8+ KB
```

- Résumé statistique des principales caractéristiques numériques du DataFrame

```
1 lfe_data.describe()
```

	wateraccess	inflation	tuberculosis	lifeexp	literacyrate	electricity
count	138.000000	138.000000	138.000000	138.000000	138.000000	138.000000
mean	88.554348	3.816283	121.607681	71.615724	90.855738	3180.130238
std	14.732248	5.065714	162.039059	8.202395	7.679331	2071.932719
min	40.000000	-1.509245	0.760000	50.621000	55.375190	139.143681
25%	81.725000	0.860427	14.000000	66.151250	90.855738	2743.672186
50%	95.350000	2.704123	53.000000	73.752500	90.855738	3180.130238
75%	99.675000	5.208063	166.500000	77.151037	93.724381	3180.130238
max	100.000000	36.906643	852.000000	83.587805	99.895903	19592.231949

Visualisation de donnée:

Cette historigramme nous permet de visualiser la tranche d'esperance de vie et sa fréquence dans notre data set, la frequence indiquant combien de pays ont une espérance de vie dans chaque intervalle spécifié

```
1 lfe_data = lfe_data.dropna()
2
3 plt.hist(lfe_data['lifeexp'], bins=30, edgecolor='black', color='skyblue')
4
5 plt.axvspan(40, 50, color='yellow', alpha=0.3, label='40-50 ans')
6 plt.axvspan(50, 60, color='orange', alpha=0.3, label='50-60 ans')
7 plt.axvspan(60, 70, color='red', alpha=0.3, label='60-70 ans')
8 plt.axvspan(70, 80, color='purple', alpha=0.3, label='70-80 ans')
9 plt.axvspan(80, 90, color='blue', alpha=0.3, label='80-90 ans')
10
11
12 plt.title('Distribution de Life Expectancy')
13 plt.xlabel('Life Expectancy')
14 plt.ylabel('Fréquence')
15 plt.legend()
16 plt.show()
```

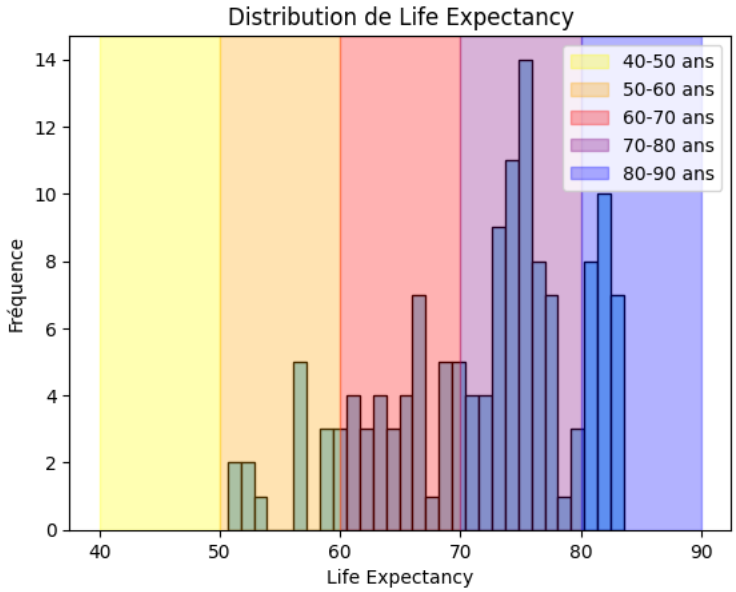

Cette historigramme nous permet de visualiser la tranche d'esperance de vie et sa fréquence dans notre data set, la frequence indiquant combien de pays ont une espérance de vie dans chaque intervalle spécifié

```
1 plt.hist(lfe_data['lifeexp'], bins=20, edgecolor='black', color='skyblue')
2 plt.title('Distribution de l\'Espérance de Vie des Pays')
3 plt.xlabel('Espérance de Vie')
4 plt.ylabel('Nombre de Pays')
5 plt.show()
```

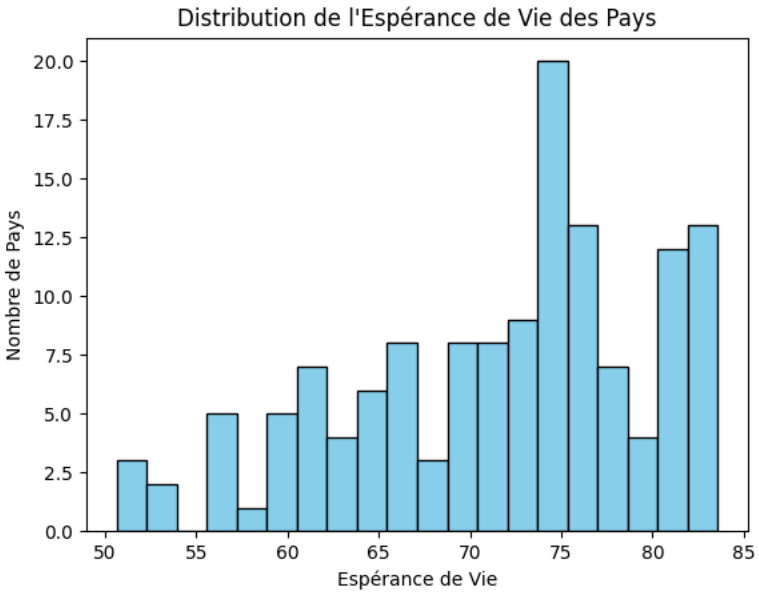

Cette matrice de corrélation montre à quel point les variables d'un ensemble de données sont liées entre elles. Dans ce notebook, elle est utilisée pour comprendre comment différentes caractéristiques (comme l'accès à l'électricité) sont corrélées à l'espérance de vie, aidant ainsi à identifier des facteurs influençant la qualité de vie dans les pays.

```
1 correlation_matrix = lfe_data.corr()
2 plt.figure(figsize=(10, 8))
3 sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', fmt=".2f")
4 plt.title('Matrice de corrélation')
5 plt.show()
```

```
<ipython-input-9-29d102897454>:1: FutureWarning: The default value of numeric_only in
  correlation_matrix = lfe_data.corr()
```

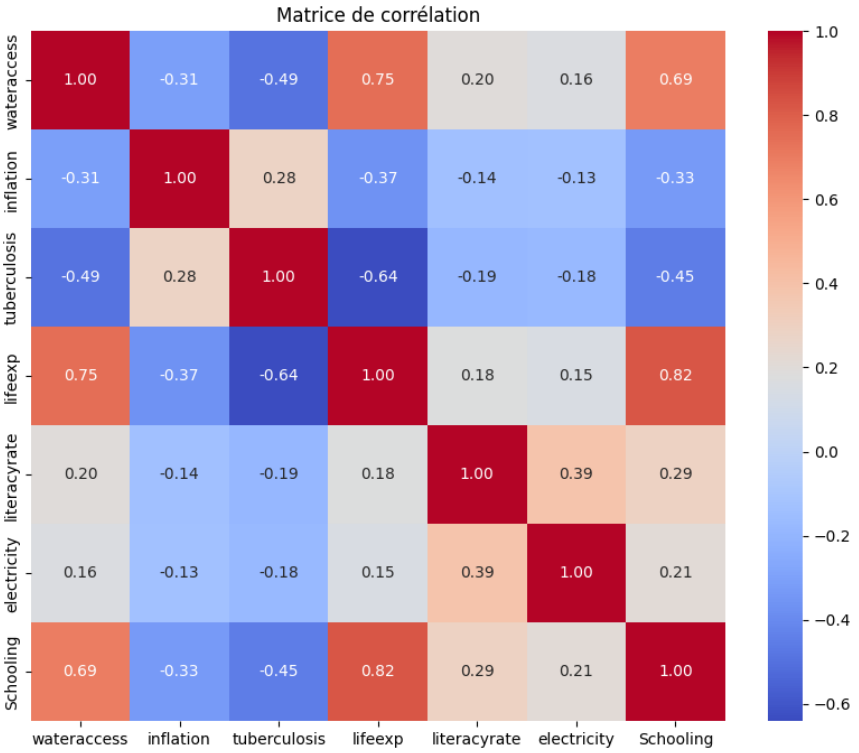

Les pays avec l'espérance de vie la plus élevée et la plus basse

```
df = lfe_data.sort_values(by='lifeexp', ascending=False)

elevee_df = df.iloc[0]  #plus élevée
basse_df = df.iloc[-1]  # plus basse

print("Pays avec l'espérance de vie la plus élévée:", elevee_df['Country'])
print("Pays avec l'espérance de vie la plus basse:", basse_df['Country'])

result = pd.DataFrame({'Country': [elevee_df['Country'], basse_df['Country']], 'Life Expectancy': [elevee_df['lifeexp'], basse_df['lifeexp']]})
sns.barplot(x='Country', y='Life Expectancy', data=result, palette ='viridis')
plt.title('Comparaison de l\'espérance de vie plus élevée vs plus basse')
plt.xlabel('Pays')
plt.ylabel('Espérance de Vie (années)')
plt.show()
```

```
Pays avec l'espérance de vie la plus élévée: Japan
Pays avec l'espérance de vie la plus basse: Central African Republic
```

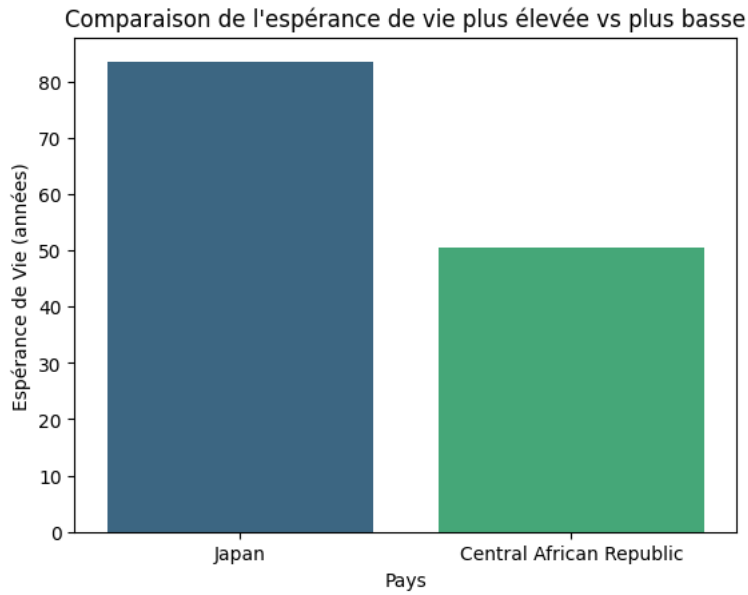

Ce diagramme en cercle montre visuellement la répartition des différents statuts de pays dans votre dataset. Chaque secteur représente un statut (développé, en développement, sous-développé) et sa taille est proportionnelle au nombre de pays ayant ce statut

```
status_counts = lfe_data['Status'].value_counts()

colors = ['orange', 'red', 'green']
plt.figure(figsize=(8, 8))
plt.pie(status_counts, labels=status_counts.index, autopct='%1.1f%%', startangle=140, colors=colors)

plt.title('Répartition des Pays par Statut de Développement')
plt.show()
```

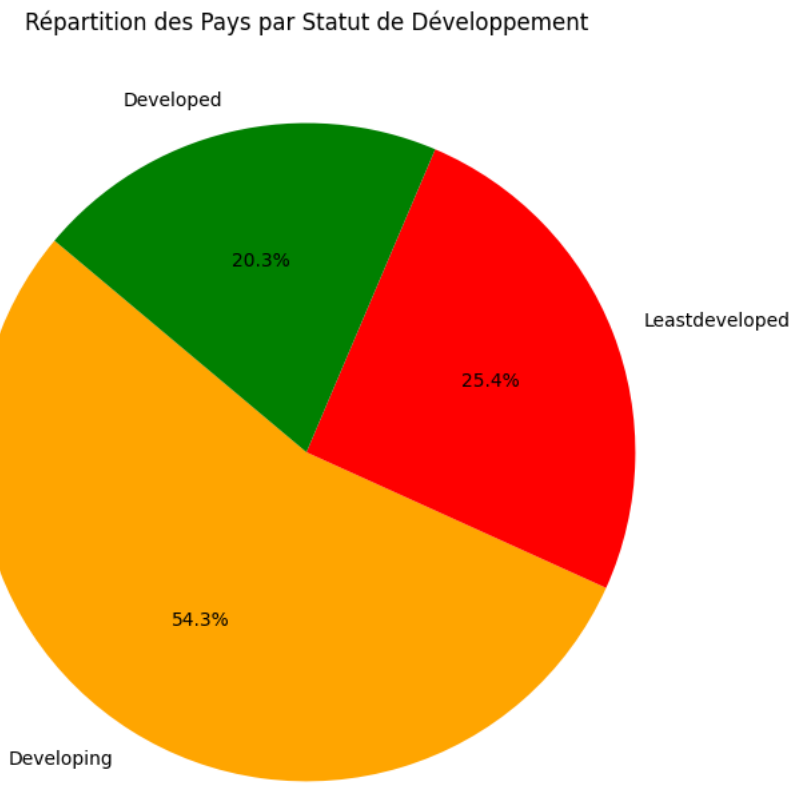

La corrélation entre le niveau de développement d'un pays (status) et son accès à l'eau potable

```
couleurs = ['skyblue', 'lightgreen', 'orange']

sns.boxplot(x='Status', y='wateraccess', data=lfe_data, palette= couleurs)
plt.title('Accès à l\'eau potable par statut')
plt.show()
```

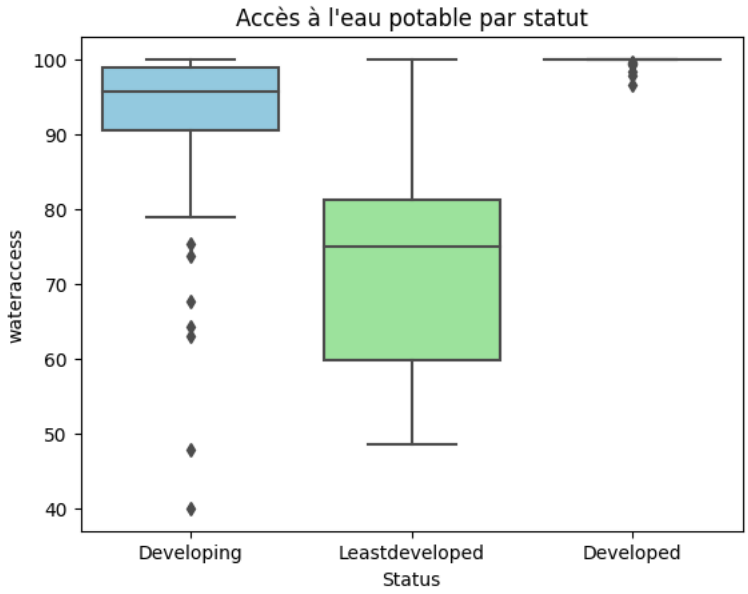

Ce graphique en nuage de points montre la relation entre l'inflation et l'espérance de vie, chaque point représentant un pays

```
sns.scatterplot(x='inflation', y='lifeexp', data= lfe_data )
plt.title('Relation entre l\'Inflation et l\'Espérance de Vie')
plt.xlabel('Inflation')
plt.ylabel('Espérence de vie')
plt.show()
```

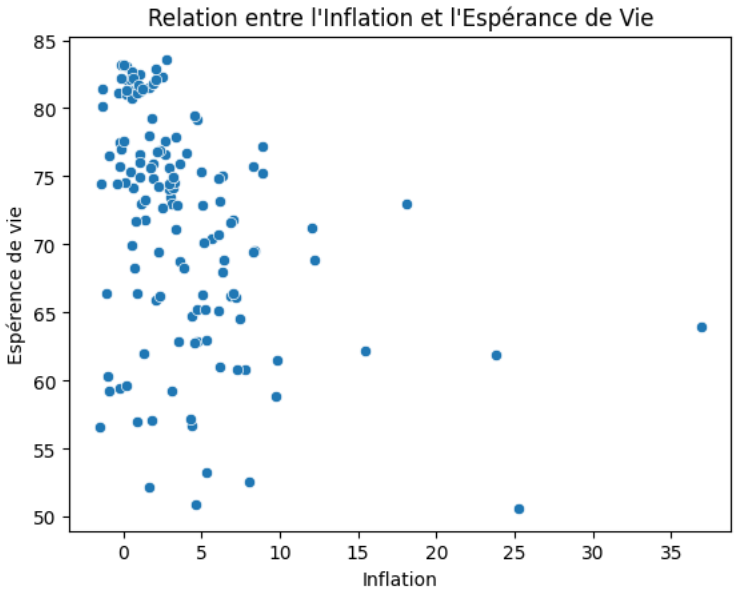

Diagramme de barres qui illustre le taux d'inflation pour différents pays

```
df = lfe_data.sort_values(by='inflation', ascending=False)

plt.figure(figsize=(20, 10))
bar_colors = sns.color_palette("viridis", len(df))
df_pays = df.head(100)

bars = plt.bar(df_pays['Country'], df_pays['inflation'], color=bar_colors)
plt.title('Inflation par pays', fontsize=16)
plt.xlabel('Pays', fontsize=14)
plt.ylabel('Inflation', fontsize=14)
plt.xticks(rotation=90, ha='center', fontsize=12)

plt.show()
```

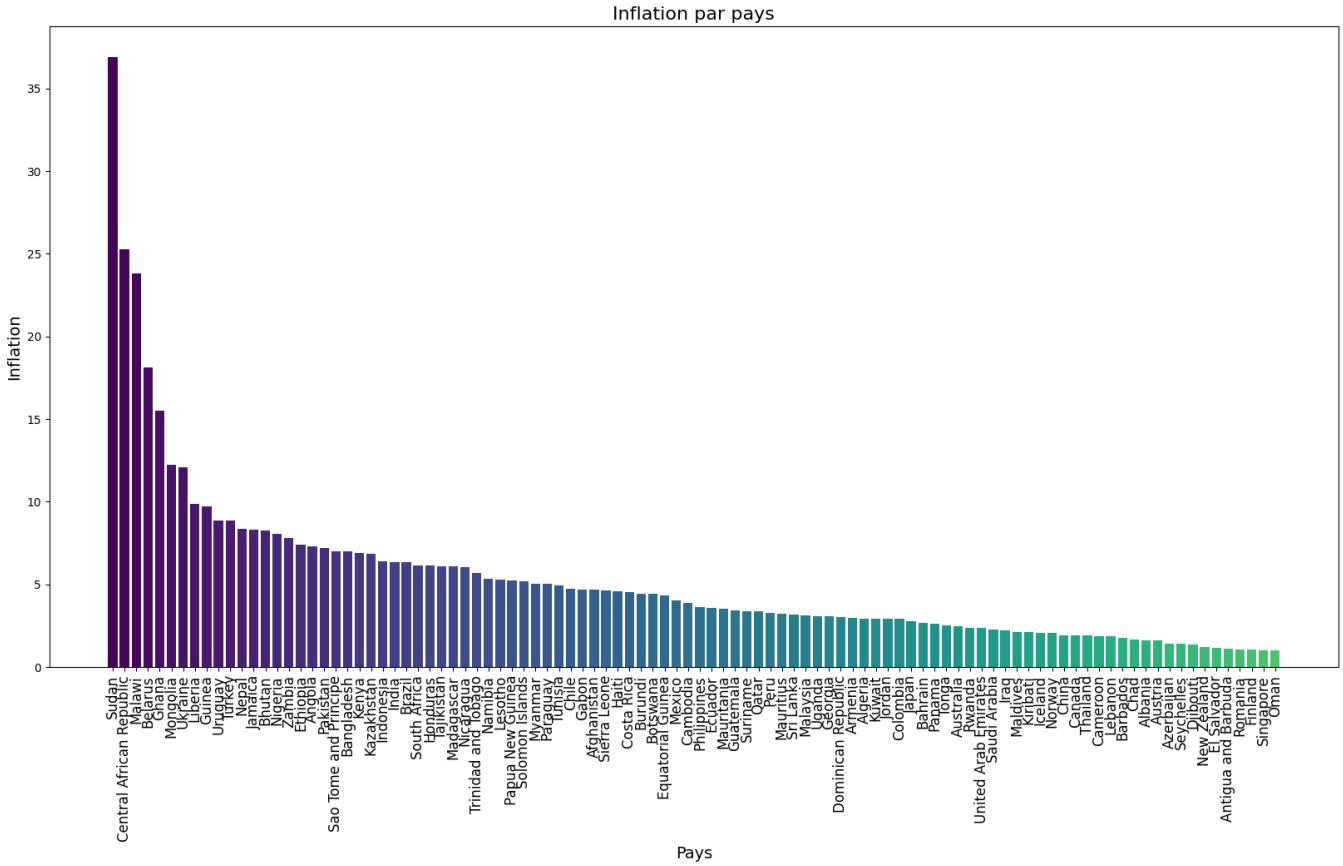

Ce diagramme conçu pour etudier le taux d'inflation dans le dataframe

```
def categorize_inflation(inflation) :
  if inflation < 0.1 :
    return 'Faible'
  elif inflation >=0.1 and  inflation < 0.4 :
    return 'Moyen'
  else :
    return 'Elevé'
lfe_data["rate of quality"] = lfe_data['inflation'].apply(categorize_inflation)

rate_of_quality = lfe_data["rate of quality"].value_counts()
colors = sns.color_palette('pastel')[0:len(rate_of_quality)]

plt.figure(figsize=(10, 6))
rate_of_quality.plot(kind="bar", color=colors)
plt.title('Répartition des Catégories d\'inflation')
plt.xlabel('Catégorie d\'Inflation')
plt.ylabel('Nombre de Pays')

plt.show()
```

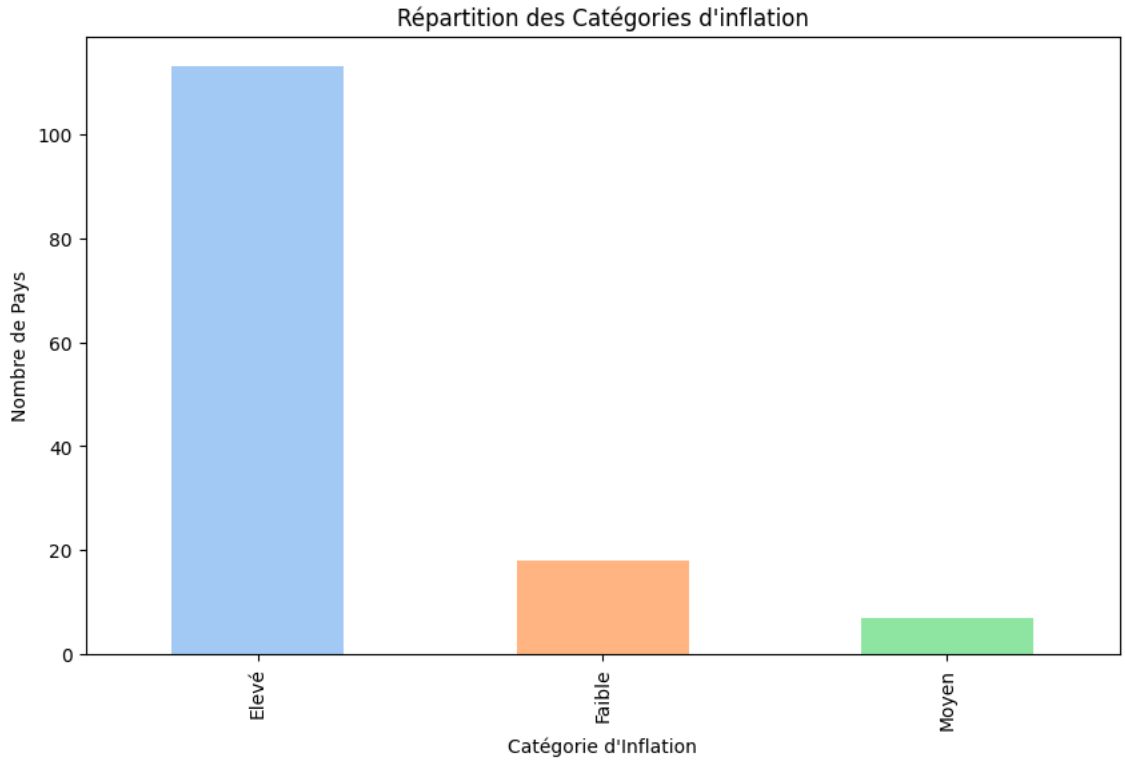

Prédiction de l'Inflation des Pays Basée sur des Indicateurs de Développement avec Régression Linéaire

```
X= lfe_data[['lifeexp', 'tuberculosis', 'literacyrate', 'wateraccess']]
y = lfe_data['inflation'] # variable cible
X_train, X_test, y_train, y_test = train_test_split(X,y,test_size = 0.5, random_state = 42)

model = LinearRegression()
model.fit(X_train, y_train)

predictions = model.predict(X_test)
predictions = model.predict(X_test)
rmse = np.sqrt(mean_squared_error(y_test, predictions)) # erreur quadratique moyenne

print("RMSE:", rmse)
```

```
RMSE: 5.763172736529843
```

Prédire la variable "wateraccess" en utilisant des modèles de classification (K-Nearest Neighbors (KNN) ou Support Vector Classifier (SVC))

```
X = lfe_data.drop('wateraccess', axis=1)
y = lfe_data['wateraccess']

X = lfe_data.select_dtypes(include=[np.number])
label_encoder = LabelEncoder()
y_encode = label_encoder.fit_transform(y)
X_train, X_test, y_train, y_test = train_test_split(X, y_encode, test_size=0.5, random_state=42)

# Normalisation des données
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# Entraînement et évaluation du modèle KNN
knn_model = KNeighborsClassifier(n_neighbors=5)
knn_model.fit(X_train_scaled, y_train)
knn_predictions = knn_model.predict(X_test_scaled)
print("KNN Model Evaluation:")
print(confusion_matrix(y_test, knn_predictions))
print(classification_report(y_test, knn_predictions))

# Entraînement et évaluation du modèle SVC
svc_model = SVC(kernel='linear')
svc_model.fit(X_train_scaled, y_train)
svc_predictions = svc_model.predict(X_test_scaled)



print("\nSVC Model Evaluation:")
print(confusion_matrix(y_test, svc_predictions))
print(classification_report(y_test, svc_predictions))
```

```
KNN Model Evaluation:
[[ 0  0  0 ...  0  0  0]
 [ 0  0  0 ...  0  0  0]
 [ 1  0  0 ...  0  0  0]
 ...
 [ 0  0  0 ...  0  0  1]
 [ 0  0  0 ...  0  0  0]
 [ 0  0  0 ...  0  0 13]]
              precision    recall  f1-score   support

           0       0.00      0.00      0.00         0
           1       0.00      0.00      0.00         0
           2       0.00      0.00      0.00         1
           3       0.00      0.00      0.00         1
           6       0.00      0.00      0.00         0
           7       0.00      0.00      0.00         1
           9       0.00      0.00      0.00         1
          11       0.00      0.00      0.00         1
          13       0.00      0.00      0.00         1
          14       0.00      0.00      0.00         0
          15       0.00      0.00      0.00         1
          16       0.00      0.00      0.00         0
          17       0.00      0.00      0.00         0
          18       0.00      0.00      0.00         1
          19       0.00      0.00      0.00         1
          20       0.00      0.00      0.00         0
          21       0.00      0.00      0.00         0
          22       0.00      0.00      0.00         0
          23       0.00      0.00      0.00         1
          24       0.00      0.00      0.00         1
          29       0.00      0.00      0.00         0
          30       0.00      0.00      0.00         1
          31       0.00      0.00      0.00         1
          32       0.00      0.00      0.00         1
          33       0.00      0.00      0.00         1
          34       0.00      0.00      0.00         1
          35       0.00      0.00      0.00         0
          36       0.00      0.00      0.00         1
          37       0.00      0.00      0.00         1
          38       0.00      0.00      0.00         1
          39       0.00      0.00      0.00         1
          41       0.00      0.00      0.00         1
          42       0.00      0.00      0.00         1
          43       0.00      0.00      0.00         1
          44       0.00      0.00      0.00         1
          45       0.00      0.00      0.00         1
          46       0.00      0.00      0.00         1
          49       0.00      0.00      0.00         2
          51       0.00      0.00      0.00         1
          53       0.00      0.00      0.00         1
          54       0.00      0.00      0.00         1
          56       0.00      0.00      0.00         0
          58       0.00      0.00      0.00         1
          59       0.00      0.00      0.00         1
          60       0.00      0.00      0.00         1
          61       0.00      0.00      0.00         2
          62       0.00      0.00      0.00         1
```

Ce box plot permet de voir la différence entre les atux de scolarisation et le status d'un pays

```
plt.figure(figsize=(10, 6))
colors  = ['skyblue', 'salmon', 'lightgreen']

sns.boxplot(x='Status', y='Schooling', data=lfe_data, palette= colors)
plt.title('Distribution du Taux de scolarisation en fonction du Statut du Pays')
plt.xlabel('Statut du pays')
plt.ylabel('Taux de Schooling')
plt.show()
```

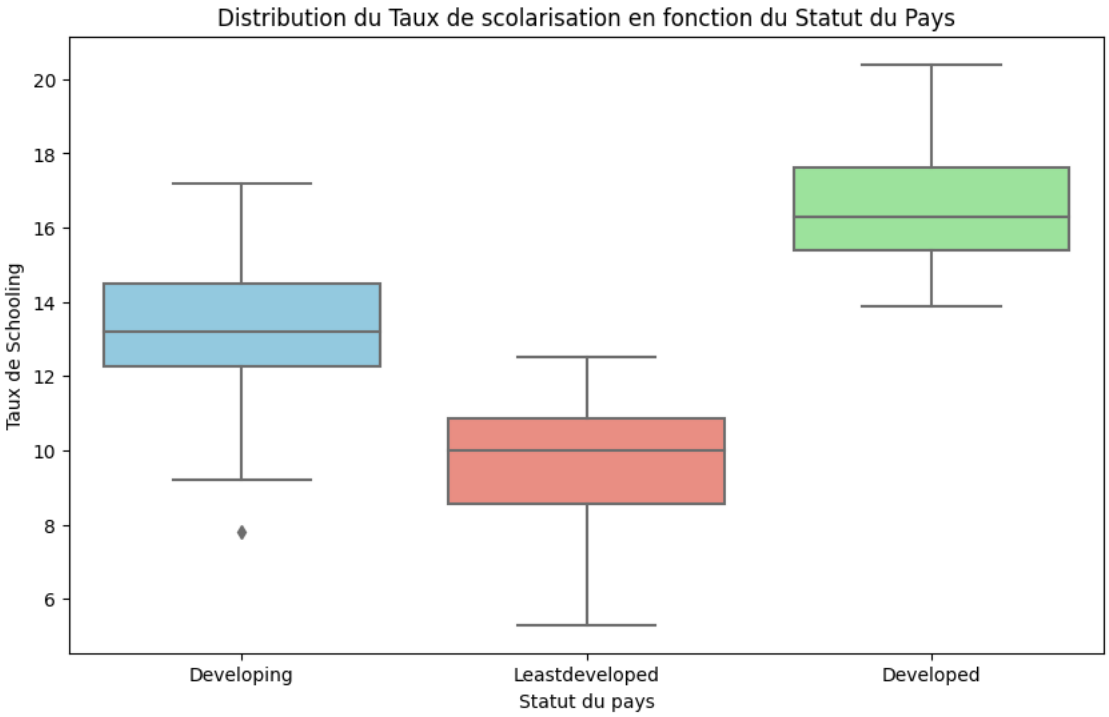

Ce diagramme chercher a mettre en lumièren la correlation entre le taux d'electrisation et le status d'un pays

```
plt.figure(figsize=(12, 8))
palette = sns.color_palette("husl", 3)
colors = {'Developed': palette[0], 'Developing': palette[1], 'Leastdeveloped': palette[2]}

lfe_data['color'] = lfe_data['Status'].map(lambda x: colors.get(x, 'gray'))

# Créer graphique de dispersion
plt.scatter(lfe_data['Status'], lfe_data['electricity'], c=lfe_data['color'], s=100)

plt.title('Relation entre Statut des Pays et Disponibilité d\'Électricité')
plt.xlabel('Statut')
plt.ylabel('Électricité')

# Ajouter une légende
legend_labels = [plt.Line2D([0], [0], marker='o', color='w', label=status,markerfacecolor=color, markersize=10) for status, color in colors.items()]
plt.legend(handles=legend_labels, title='Statut')
plt.show()
```

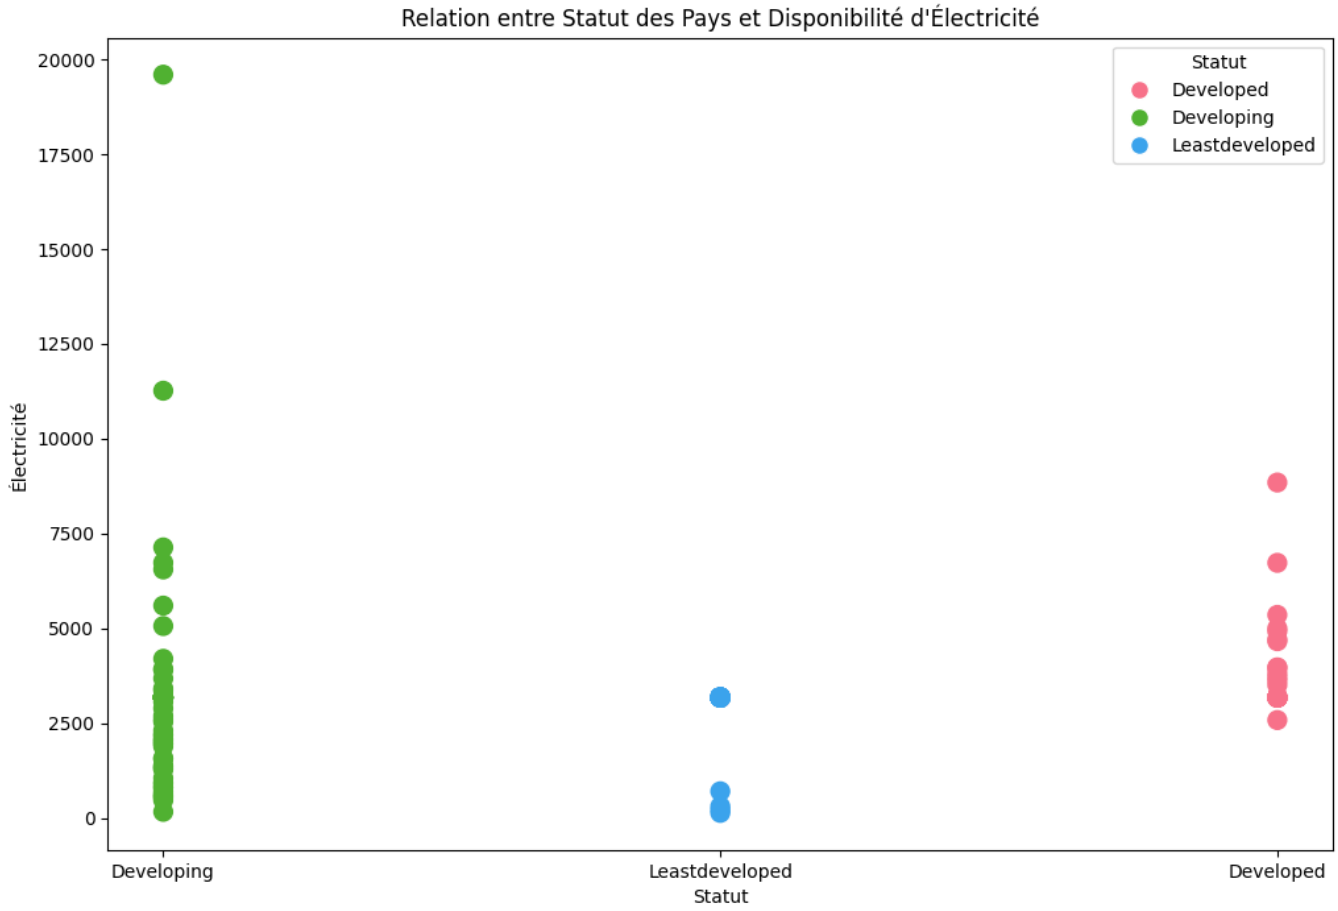

Analyse de Régression Linéaire pour la Prédiction de l'Espérance de Vie

```
X = lfe_data[['wateraccess', 'tuberculosis', 'literacyrate', 'electricity', 'Schooling']]
y = lfe_data['lifeexp'] #variable cible

#division en ensembles d'entraînement et de test
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Création et entraînement du modèle
model = LinearRegression()
model.fit(X_train, y_train)

# Prédiction sur l'ensemble de test
y_pred = model.predict(X_test)
# Calcul de l'erreur quadratique moyenne et du coefficient de détermination
mse = mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print(f"Erreur quadratique moyenne (MSE) : {mse}")
print(f"Coefficient de détermination (R^2) : {r2}")
plt.scatter(y_test, y_pred, alpha=0.5)
plt.title("Régression Linéaire : valeurs réelles vs prédites ")
plt.xlabel("valeurs réelles")
plt.ylabel("valeurs rrédites")
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()], 'k--', lw=2)
plt.show()
```

```
Erreur quadratique moyenne (MSE) : 13.538435218423952
Coefficient de détermination (R^2) : 0.8030876962775488
```

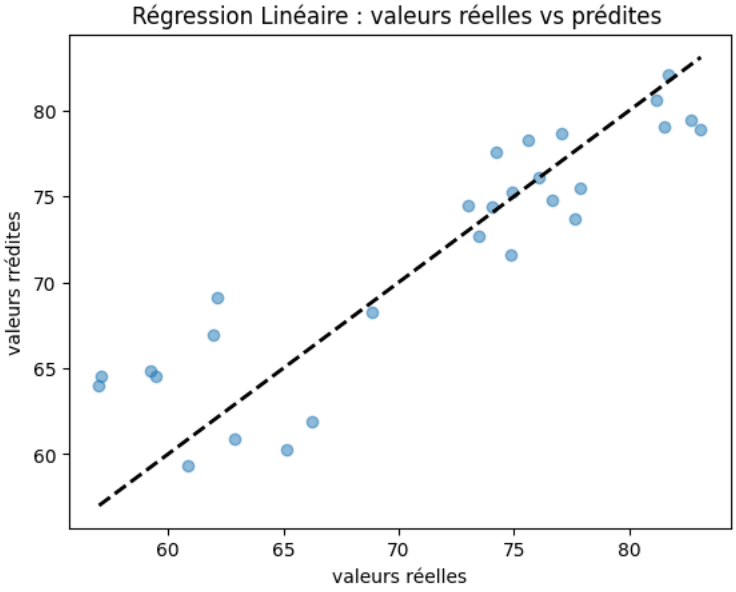


```
selected_columns = ["wateraccess", "inflation", "tuberculosis", "lifeexp", "literacyrate", "electricity", "Schooling"]
data = df[selected_columns]

# Normalisation des données
scaler = StandardScaler()
normalized_data = scaler.fit_transform(data)

# Application de l'algorithme de clustering hiérarchique
clustering = AgglomerativeClustering(n_clusters=3, linkage='ward')
df['Cluster'] = clustering.fit_predict(normalized_data)

# Visualisation des clusters
sns.pairplot(df, hue='Cluster', diag_kind='kde', palette='Dark2')
plt.show()

```

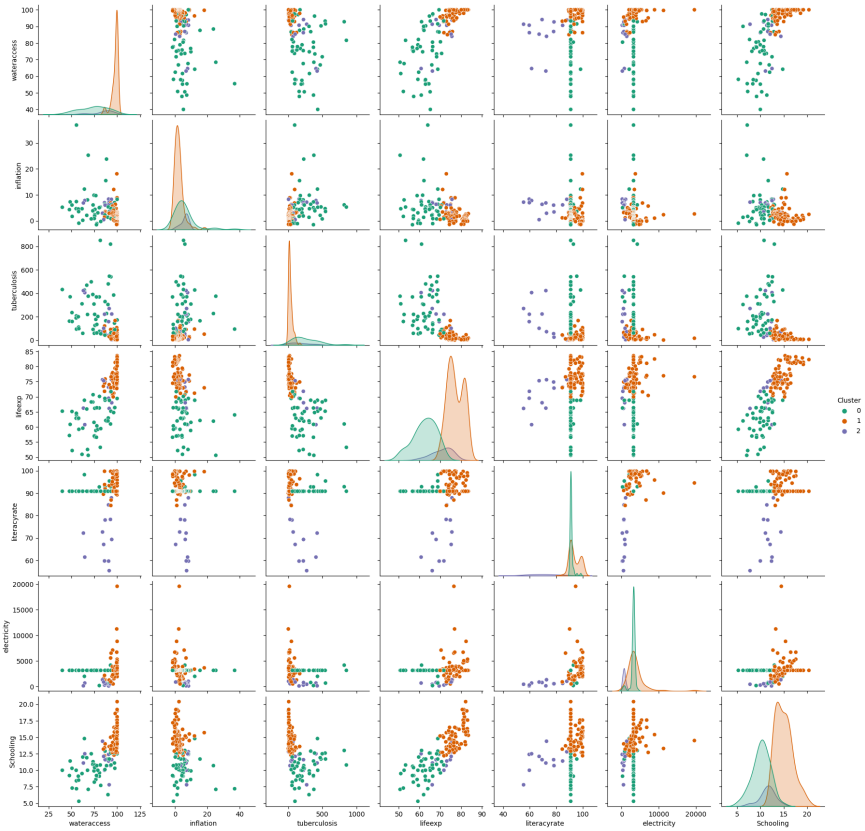
wateraccess
inflation
tuberculosis
lifeexp
literacyrate
electricity
Schooling
Cluster
0
1
2